

金融机器学习综合应用报告

基于离线强化学习、QLBS、逆强化学习与大模型的实践

课程名称：金融数学：理论与 AI 应用

学生姓名：马伟祥

学号：25214020012

2025 年 12 月 18 日

摘要

本报告旨在通过前沿的机器学习方法解决四个具体的金融场景问题。首先，针对高频做市商场景 (Ch.9)，构建了基于库存惩罚的 MDP 模型，并采用 Fitted Q-Iteration (FQI) 算法解决了离线数据下的策略优化问题。其次，在期权对冲任务 (Ch.10) 中，复现了 QLBS 模型，利用 Q 函数的二次结构推导了解析解，在存在交易成本和离散对冲的市场中实现了优于 Black-Scholes Delta 的表现。第三，针对智能催收系统的黑盒策略重构 (Ch.11)，采用最大熵逆强化学习 (MaxEnt IRL) 恢复了专家的隐性偏好，通过特征期望匹配解决了行为克隆的鲁棒性问题。最后，设计了基于感知-决策闭环的 LLM 金融决策系统 (Ch.12)，引入信息瓶颈 (IB) 理论和联合学习框架，有效提升了模型对非结构化文本噪声的鲁棒性。报告包含完整的数学推导、算法实现细节、实验结果分析及模型风险审计。

目录

1 序贯决策建模与离线强化学习 (Ch.9)	3
1.1 1.1 MDP 建模 (Question a)	3
1.2 1.2 离线 RL 场景与 FQI 算法 (Question b)	3
1.3 1.3 离线策略评估 (OPE) 方法 (Question c)	4
1.4 实验结果与上线安全考量 (Question d)	4
2 QLBS：期权对冲的强化学习方法 (Ch.10)	6
2.1 2.1 模型建构 (Question a)	6
2.2 2.2 求解算法：解析最优动作 (Question b)	6
2.3 2.3 实验结果与指标 (Question c)	6
2.4 风险审计	7
3 逆强化学习：智能催收偏好恢复 (Ch.11)	8
3.1 3.1 行为克隆失败原因与方法对比 (Question a)	8
3.2 3.2 MaxEnt IRL 方法与流程 (Question b)	8
3.3 3.3 奖励迁移性与挑战 (Question c)	8
3.4 原型系统与实验结果 (Question d)	9
4 感知-决策闭环与 LLM 融合建模 (Ch.12)	10
4.1 4.1 架构设计：LLM-Augmented POMDP (Question a)	10
4.2 4.2 联合学习与两阶段局限性 (Question b)	10
4.3 4.3 信息瓶颈 (IB) 提升鲁棒性 (Question c)	10
4.4 原型设计与鲁棒性实验 (Question d)	10

1 序贯决策建模与离线强化学习 (Ch.9)

1.1 1.1 MDP 建模 (Question a)

我们将高频做市商 (Market Maker) 的限价单簿 (LOB) 交易策略建模为有限视界马尔可夫决策过程 (MDP)，定义五元组 $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ ：

- **状态空间 \mathcal{S}** : $s_t = (t, q_t, W_t, P_t)$ 。
 - $t \in [0, T]$: 剩余交易时间。
 - $q_t \in \{-Q_{max}, \dots, Q_{max}\}$: 当前持仓库存。
 - W_t : 当前总财富 (现金 + 库存市值)。
 - P_t : 市场中间价 (Mid-price)。
- **动作空间 \mathcal{A}** : $a_t = (\delta_t^b, \delta_t^a)$ 。即设定买单和卖单相对于中间价的价差 (Spread)。为适应 FQI 算法，我们将动作离散化为三个档位: {Tight (激进), Neutral (中性), Wide (保守)}。
- **奖励函数 \mathcal{R}** : 目标是最大化风险调整后的 PnL。

$$r_t(s_t, a_t) = \Delta W_t - \eta(q_t)^2 \quad (1)$$

其中 ΔW_t 为财富增量， $\eta(q_t)^2$ 为库存惩罚项。该项是 Avellaneda-Stoikov 模型的离散化体现，迫使智能体在库存偏离 0 时采取激进平仓动作，从而控制存货风险。

- **转移概率 \mathcal{P}** : 库存演变遵循受控泊松过程: $q_{t+1} = q_t + \mathbb{I}_{fill_bid} - \mathbb{I}_{fill_ask}$ 。成交概率 $\lambda(\delta) \propto e^{-k\delta}$ 取决于市场深度和动作 δ 。
- **折扣因子 γ** : 设为 1.0 (有限视界任务，关注最终总收益)。

1.2 1.2 离线 RL 场景与 FQI 算法 (Question b)

为什么是离线 (Offline/Batch) RL ?

1. **探索成本 (Cost of Exploration)**: 在真实 LOB 中进行 ϵ -greedy 在线探索会导致被套利者 “收割”，产生直接的经济损失。
2. **数据特性**: 交易所拥有海量的历史 LOB 数据 (Logged Data)，这些数据由历史策略生成，包含了丰富的市场微观结构信息。

算法选择: Fitted Q-Iteration (FQI) 我们选择 FQI 算法 (Dixon Ch.9 Sec 9.6)，因为它能有效利用批量数据，并将 RL 问题转化为监督回归问题。

Algorithm 1: Fitted Q-Iteration (FQI) for Market Making

Input: Dataset $\mathcal{D} = \{(s_i, a_i, r_i, s'_i)\}_{i=1}^N$, Regressor \mathcal{F} (e.g., XGBoost)

```

1 初始化  $Q_0(s, a) \leftarrow 0$ ;
2 for  $k = 1$  to  $K$  do
3   构造回归目标集  $\mathcal{T} = \emptyset$ ;
4   for each sample  $i$  in  $\mathcal{D}$  do
5      $y_i = r_i + \gamma \max_{a' \in \mathcal{A}} Q_{k-1}(s'_i, a')$ ;
6     Add  $((s_i, a_i), y_i)$  to  $\mathcal{T}$ ;
7   训练回归模型  $\mathcal{F}$  拟合  $\mathcal{T}$ ;
8    $Q_k \leftarrow \mathcal{F}$ ;

```

Output: Greedy Policy $\pi(s) = \arg \max_a Q_K(s, a)$

1.3 离线策略评估 (OPE) 方法 (Question c)

由于无法在实盘测试，我们设计两种 OPE 方法：

1. **Fitted Q Evaluation (FQE):** 类似于 FQI，但固定策略 π_{new} ，迭代计算 Q^π 。

$$y_i = r_i + \gamma Q_{k-1}(s'_i, \pi_{new}(s'_i))$$

评价：FQE 在长序列金融任务中方差较低，适合做市场景。

2. **加权重要性采样 (WIS):** 利用重要性权重 $\rho_t = \frac{\pi_{new}(a_t|s_t)}{\pi_{old}(a_t|s_t)}$ 对历史回报加权。局限：
当视界 T 较长时，权重连乘会导致方差指数爆炸，但在短视界内可作为无偏估计的补充。

1.4 实验结果与上线安全考量 (Question d)

我们对比了朴素策略（随机报价）与 RL 策略的库存路径。




图 1: 做市商库存控制对比实验

如图 1 所示，RL 策略（红线）表现出显著的 ** 均值回归 ** 特性，有效避免了朴素策略（灰线）的库存发散风险。

上线安全性与合规性 (Guardrails):

- 硬约束:** 设置代码级熔断，当 $|q_t| \geq Q_{limit}$ 时，强制覆盖模型输出，禁止同方向开仓。
- 分布漂移监控:** 实时监控市场波动率 σ_t 。若测试环境与训练数据的 KL 散度超过阈值，自动回退至 Avellaneda-Stoikov 解析解。

2 QLBS：期权对冲的强化学习方法 (Ch.10)

2.1 2.1 模型建构 (Question a)

我们将期权对冲问题转化为 MDP，旨在最小化对冲误差方差。

- **状态:** $X_t = [t, S_t]$ (时间, 股价)。在更复杂的设置中可包含隐含波动率 I_t 。
- **动作:** $a_t \in \mathbb{R}$, 表示持有标的资产的数量 (Hedge Ratio)。
- **奖励函数:**

$$R_t = -\left(\Delta \hat{C}_t - a_t \Delta S_t\right)^2 - \lambda |a_t - a_{t-1}| \quad (2)$$

其中第一项为对冲误差的平方 (方差), 第二项为成比例交易成本。 λ 控制对交易摩擦的敏感度。

2.2 2.2 求解算法：解析最优动作 (Question b)

QLBS 的核心创新在于利用 Q 函数的二次结构。在 Black-Scholes 假设下, Q 函数可参数化为:

$$Q_t^*(X_t, a_t) = -\left(\mathcal{A}_t(X_t)a_t^2 + \mathcal{B}_t(X_t)a_t + \mathcal{C}_t(X_t)\right) \quad (3)$$

其中 $\mathcal{A}, \mathcal{B}, \mathcal{C}$ 仅依赖于状态。为了最大化 Q 值 (即最小化成本), 我们令 $\frac{\partial Q}{\partial a} = 0$, 得到解析解:

$$a_t^*(X_t) = -\frac{\mathcal{B}_t(X_t)}{2\mathcal{A}_t(X_t)} \quad (4)$$

这一公式避免了数值优化 (如梯度下降) 的不稳定性, 且计算速度极快。我们在实现中采用反向归纳法, 从 $t = T - 1$ 到 0, 利用基函数 (Laguerre 多项式) 递归回归求解系数 $\mathcal{A}_t, \mathcal{B}_t, \mathcal{C}_t$ 。

2.3 2.3 实验结果与指标 (Question c)

我们在存在交易成本 ($\lambda > 0$) 的模拟市场中, 对比了 QLBS 与标准 BS Delta 对冲的性能。




图 2: 对冲误差分布对比 (PnL)

实验分析:

- **分布形态:** 如图 2, QLBS (橙色) 的误差分布峰度更高, 尾部更窄。BS 对冲 (蓝色) 由于频繁调仓产生了较高的交易成本, 导致均值左偏。
- **评估指标:**
 - MSHE (均方对冲误差): QLBS 低于 BS 约 15%。
 - 总交易成本: QLBS 显著降低了换手率, 实现了“稀疏对冲”。

2.4 风险审计

数值稳定性: 若 $\mathcal{A}_t(X_t) \approx 0$ (如深度虚值期权), 解析解可能发散。我们通过 Tikhonov 正则化 (Ridge Regression) 和动作截断 (Clipping) 来解决此数值问题。

3 逆强化学习：智能催收偏好恢复 (Ch.11)

3.1 3.1 行为克隆失败原因与方法对比 (Question a)

行为克隆 (BC) 的局限性：

1. **复合误差 (Compounding Error)**: BC 仅拟合单步动作 $a_t \sim \pi(s_t)$ 。一旦在 t 时刻产生微小偏差，系统进入训练数据未覆盖的状态分布 (Distribution Shift)，误差将在后续步骤中级联放大，导致 $O(T^2)$ 的累积遗憾。
2. **不可解释与不可迁移**: BC 无法理解动作背后的动机 (如“为何在此处不打电话”)。当经济环境变化导致还款概率改变时，BC 策略直接失效。

IL vs IRL: IRL 旨在恢复奖励函数 $R(s)$ ，这是对专家意图的更本质抽象。学到的 $R(s)$ (如：合规惩罚权重) 在不同环境下更具鲁棒性和可迁移性。

3.2 3.2 MaxEnt IRL 方法与流程 (Question b)

我们选择 ** 最大熵 IRL (MaxEnt IRL)**。其目标是使策略的特征期望匹配专家的特征期望，同时保持策略分布的熵最大。

$$\min_{\theta} \|\mathbb{E}_{\pi_{\theta}}[\phi(s)] - \mathbb{E}_{\text{Expert}}[\phi(s)]\| \quad (5)$$

训练流程：

1. **统计专家特征**：计算历史日志的特征均值 $\hat{\mu}_E$ 。
2. **内层循环 (RL Solver)**：在当前 R_{θ} 下，训练 PPO 智能体得到最优策略 π_{θ} 。
3. **外层循环 (Reward Update)**：计算 π_{θ} 的特征期望 $\hat{\mu}_{\pi}$ ，并利用梯度下降更新 θ ：

$$\theta \leftarrow \theta + \alpha(\hat{\mu}_E - \hat{\mu}_{\pi})$$

3.3 3.3 奖励迁移性与挑战 (Question c)

不可辨识性 (Identifiability)：存在多个 R 对应同一最优策略。解决方案：

- 使用 L1 正则化，鼓励稀疏的奖励结构。
- 特征工程：严禁使用 UserID 等 ID 类特征。必须使用具有 ** 因果关系 ** 的通用特征 (如：Risk Score, DTI Ratio, Promise Rate)，确保奖励函数在不同用户群间可迁移。

3.4 3.4 原型系统与实验结果 (Question d)

我们构建了包含 Expert Buffer, Reward Net 和 PPO Agent 的原型系统。




图 3: 特征期望匹配性能对比

如图 3 所示, MaxEnt IRL (蓝色) 在所有关键业务特征上均能精确复现专家的分布, 而 BC (灰色) 出现了显著偏差, 验证了 IRL 在捕捉隐性偏好方面的有效性。

4 感知-决策闭环与 LLM 融合建模 (Ch.12)

4.1 4.1 架构设计：LLM-Augmented POMDP (Question a)

针对客服/催收场景，我们设计如下感知-决策架构：

- **观测** o_t : 非结构化的用户对话文本、语音转录。
- **表征** $z_t = f_\phi(o_t)$: 由 LLM 编码器提取的低维状态向量（包含意图、情绪、风险标签）。
- **策略** $\pi_\theta(a_t|z_t)$: 基于表征 z_t 进行动作选择的 RL 策略网络。
- **环境转移** $s_{t+1} \sim P(\cdot|s_t, a_t)$: 用户的真实状态演变。

4.2 4.2 联合学习与两阶段局限性 (Question b)

两阶段 (Two-stage) 的局限: 如果感知模块仅针对 NLP 任务（如情感分类）优化，可能会丢弃对最终决策（如回款）至关重要的微弱信号（目标错位）。且决策模块对感知误差高度敏感。

联合学习 (Joint Learning) 方案: 构建端到端计算图，将 RL 的价值梯度 $\nabla J(\theta)$ 反向传播至 LLM 适配器 (Adapter) 参数 ϕ :

$$\max_{\phi, \theta} \mathbb{E}_{\tau \sim \pi_\theta(f_\phi)} \left[\sum \gamma^t R_t \right] \quad (6)$$

这迫使 LLM 学会提取“对决策有用”的特征。

4.3 4.3 信息瓶颈 (IB) 提升鲁棒性 (Question c)

为防止 LLM 对 Prompt 中的噪声（如无关闲聊）过拟合，我们引入 ** 信息瓶颈 (Information Bottleneck)** 正则化：

$$\min_{\phi} I(o_t; z_t) - \beta I(z_t; R_t) \quad (7)$$

通过最小化 o_t 与 z_t 的互信息，系统被迫压缩掉冗余信息，仅保留最具预测性的核心特征，从而提升泛化能力。

4.4 4.4 原型设计与鲁棒性实验 (Question d)

LLM Prompt 与 Fallback: 我们采用结构化 Prompt 强制 LLM 输出 JSON。

```

1 response = LLM.generate(prompt)
2 if not is_valid_json(response) or confidence < threshold:
3     # Deterministic Rule-Based Fallback

```

```

4     action = RuleEngine.get_safe_action()
5 else:
6     state = parse_json(response)
7     action = RL_Agent.act(state)

```

Listing 1: Fallback Logic




图 4: 输入噪声下的系统鲁棒性分析

实验结果: 如图 4, 联合学习 +IB 模型 (蓝线) 在噪声水平升高时, 决策准确率衰减显著慢于冻结参数的基线模型 (灰线)。

漂移监控: 建立监控机制, 每日计算 Prompt 输出 Embedding 的 Wasserstein 距离。若检测到分布漂移 (如 LLM 版本更新导致), 立即冻结自动策略并报警。